Projet : Fouille de Données

Thème : Classification et clustering des tweets en Python.

Réaliser par : Mannai Salim

Objectifs :

- Maitriser l'API de twitter pour l'extraction des tweets
- Maitriser la partie NLP (natural language processing) avec NLTK en Python
- Appliquer les principes de nettoyage des données
- Classer les tweets : regrouper ensemble les tweets qui sont similaires. C'est une étape qui peut être considérée comme une étape

Twitter

Twitter est un service de réseautage social et de micro-blogging sur lequel les utilisateurs publient et interagissent les uns avec les autres via des messages appelés «tweets». Il est classé au 6e rang des sites et applications de réseautage social les plus populaires par Dream Grow en avril 2020 avec une moyenne de 330 millions d'utilisateurs actifs par mois.

Spécifications

Imaginons que vous avez un compte Twitter, et que vous lez suivre les tweets (texte très court) sur ce réseau social. Vu le nombre colossal de Tweets, et faute de temps, vous n'avez pas la possibilité de les lire tous. Pour cela, vous avez besoin d'une application qui va jouer le rôle d'assistantet qui va vous effectuer un résumé de toutes ces informations. Une des approches qu'on peut utiliser estde le classer sous former de groupes de sorte à ce qu'on présente à l'utilisateur un seul Tweet de chaque groupe. Pour cela, on doit procéder en trois grandes étapes :

1. Prétraitement des tweets

Dans cette étape, l'objectif est d'éliminer le texte inutile des tweets tels que les #, les noms des utilisateurs, les url, …

2. Traitement des tweets : NLP (Natural LanguageProcessing) On doit procéder à l'analyse du tweet en respectant les différentes étapes du NLP (Natural LanguageProcessing). La bibliothèque à utiliser est NLTK en Python.
3. Classification des tweets Etant donné un ensemble de tweets, l'objectif est de les résumer sous formes de groupes de sorte à ce que les Tweets qui sont dans le même groupe soient similaires. Ainsi, l'utilisateur pourra par la suite lire juste un Tweet de chaque groupe (le Tweet qui est le centroïde de groupes).

Réalisation:

Librairies

Les bibliothèques suivantes seront utilisées tout au long du projet.

In [1]:
```
#pip install tweepy
#!python -m spacy download en_core_web_sm
#!pip install spacy
```

In [2]:
```
import pandas as pd
import spacy
import en_core_web_sm
import tweepy
import numpy as np
import datetime
import csv
import matplotlib.pyplot as plt
import seaborn as sns
import re
from sklearn.model_selection import train_test_split
import nltk
from nltk.tokenize import RegexpTokenizer, WhitespaceTokenizer
from nltk.stem import WordNetLemmatizer
from nltk.corpus import stopwords
import string
from string import punctuation
import collections
from collections import Counter
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer
from sklearn.feature_extraction.text import CountVectorizer, TfidfTransformer
from sklearn.metrics.pairwise import cosine_similarity
from sklearn.metrics import jaccard_score
from sklearn.feature_extraction.text import CountVectorizer
%matplotlib inline
```

Base de données

On va télécharger les Tweets à partir de Twitter en utilisant l'API de twitter. Pour cela, on doit obetenir un compte « Twitter Developer ».

In [3]:
```
auth = tweepy.OAuthHandler('aKIxg8MbtYW6lhDIWU9v2p8VA', 'wVSlCIfFQQigcJ1tssZjmrA9
auth.set_access_token('1328822985235591176-YL808qohOui7bkw5db669OwwxWFvH7', 'iN79

api = tweepy.API(auth, wait_on_rate_limit=True)

public_tweets = api.home_timeline()
for tweet in public_tweets:
    print(tweet.text)
```

```
McConnell urged Republican senators not to object when Congress ratifies presid
ential votes https://t.co/Ovjk92Y2MX (https://t.co/Ovjk92Y2MX) https://t.co/pr4
S9KRA0I (https://t.co/pr4S9KRA0I)
Hundreds of public servants and nonprofit employees across the U.S. are scrambl
ing to unload hundreds of millions i… https://t.co/bqQweAyi6w (https://t.co/bqQ
weAyi6w)
هجمات إلكترونية تخترق إدارات فيدرالية ومواقع وزارات أميركية، و #واشنطن تتهم #روسيا https://t.co/wItRwf
zpGZ (https://t.co/wItRwfzpGZ)
President-elect Joe Biden has tapped Pete Buttigieg to lead the U.S. Transporta
tion Department, making him the firs… https://t.co/ptuth78IAt (https://t.co/ptu
th78IAt)
سيتي يكتفي بالتعادل على أرضه مع بروميتش
#سكاي_رياضة
https://t.co/kEv9bpAeXS (https://t.co/kEv9bpAeXS)
Vaccin contre le Covid-19: l'Agence européenne des médicaments sous pression ht
tps://t.co/1WKaT3SxdG (https://t.co/1WKaT3SxdG) https://t.co/ljrJbdvzZY (http
s://t.co/ljrJbdvzZY)
President-elect Joe Biden is poised to tap former Michigan Gov. Jennifer Granho
lm to lead the Department of Energy,… https://t.co/sZeDoYZNFt (https://t.co/sZe
DoYZNFt)
Happy 6th birthday to #ThePinkprint &amp;amp; thank you guys for rockin w|me 😘🙀
🦄🎧
Google says looking into Gmail outage issue https://t.co/C3QbyabhAL (https://t.
co/C3QbyabhAL) https://t.co/H6TMw4FX5C (https://t.co/H6TMw4FX5C)
Facebook will move UK users to US terms, avoiding EU privacy laws https://t.co/
jJjEqkZ7ev (https://t.co/jJjEqkZ7ev)
الداخلية»: الإخوان يروجون شائعة انتشار كورونا في السجون لتأليب الرأي العام«

https://t.co/GMmSreAyQc (https://t.co/GMmSreAyQc) https://t.co/KQJFn6NIdC (http
s://t.co/KQJFn6NIdC)
OP-ED: In Georgia, Unsigned Absentee Ballots, Shown on Video adds to the Stench
of Election Corruption https://t.co/rOV13WIwTb (https://t.co/rOV13WIwTb)
الغندور" بعد اعتداء أولاده عليه: رموني في الشارع وأهل الخير ساعدوني"
https://t.co/5tPWC4iDEk (https://t.co/5tPWC4iDEk)
إسرائيل تتوقع سلاماً مع عمان وإندونيسيا https://t.co/I4YIau6Uvj (https://t.co/I4YIau6Uvj)
رئيس الوزراء الروسي يوقّع على قائمة من الأوامر التي ترمي إلى تحقيق الاستقرار لأسعار الغذاء

الرابط البديل:… https://t.co/XiN0Chnj6a (https://t.co/XiN0Chnj6a)
Volkswagen has defused a power struggle over measures needed to accelerate its
 expansion in electric vehicles, lift… https://t.co/R9ZeftpNE9 (https://t.co/R9
ZeftpNE9)
سميحه_ايوب: تركت بيت أهلى سنة بسبب رفضهم دخولى معهد الفنون المسرحية#
https://t.co/fFEln6L9sS (https://t.co/fFEln6L9sS) https://t.co/0cOJ2SZixu (http
s://t.co/0cOJ2SZixu)
بنزيمة يسجّل ثنائية ويقود #ريال_مدريد إلى فوز ثمين على حساب أتلتيك بيلباو في الليغا#

الدوري_الإسباني# https://t.co/Y7FvKhOkHp (https://t.co/Y7FvKhOkHp)
Thank you, baby. 😘 https://t.co/wmYBjuxocr (https://t.co/wmYBjuxocr)
```

```
As for the Pfizer-BioNTech vaccine, which is already being administered in Cana
da, we’ve confirmed that about 200,0… https://t.co/5cEIv2Us7r (https://t.co/5cE
Iv2Us7r)
```

In [4]:
```
user = api.get_user('twitter')
```

In [5]:
```
print(user.screen_name)
print(user.followers_count)
for friend in user.friends():
   print(friend.screen_name)
```

```
Twitter
58696167
angnickelodeon
```

- Maintenant on va sauvgarder les tweets dansun fichier csv
- j'ai choisit 12,000 tweets puisque on vas travailler avec 10,000 donc apres le 'Data cleaning' et sur tt le l'enlèvement des redondance le nombre vas se réduit.

In [ ]:
```
filename = 'Datasets/twitter_data_analysis'+(datetime.datetime.now().strftime("%Y
with open (filename, 'w', newline='',encoding="utf-8") as csvFile:
    csvWriter = csv.writer(csvFile)
    csvWriter.writerow(['date', 'TweetId','Tweet','created_at','geo','place','coo
    #using tweepy Cursor
    for tweet in tweepy.Cursor(api.search,q='#',lang="en",since="2020-10-01").ite
        csvWriter.writerow([datetime.datetime.now().strftime("%Y-%m-%d  %H:%M"),
```

apres avoir télécharger les tweets , une dataframe vas etre creès pour q'on puisse manipuler ces données.

- Affichage de la taille du dataset (n_lignes and n_colonnes)

In [3]:
```
tweet_df= pd.read_csv('Datasets/twitter_data_analysis2020-12-11-21.csv')
print('Dataset size:',tweet_df.shape)
print('Columns are:',tweet_df.columns)
tweet_df.info()
```

```
Dataset size: (12000, 8)
Columns are: Index(['date', 'TweetId', 'Tweet', 'created_at', 'geo', 'place',
'coordinates',
       'location'],
      dtype='object')
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 12000 entries, 0 to 11999
Data columns (total 8 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   date         12000 non-null  object
 1   TweetId      12000 non-null  int64
 2   Tweet        12000 non-null  object
 3   created_at   12000 non-null  object
 4   geo          14 non-null     object
 5   place        143 non-null    object
 6   coordinates  14 non-null     object
 7   location     8120 non-null   object
dtypes: int64(1), object(7)
memory usage: 750.1+ KB
```

- Puisque on vas manipuler seulement les text des tweets , donc on vas garder que la colonne de l'identificateur des tweets et les texts des tweets.

In [4]:
```
df  = pd.DataFrame(tweet_df[['TweetId', 'Tweet']])
```

Prétraitement

Les tweets contiennent des objets inutiles tels que des hashtags, des mentions, des liens et des signes de ponctuation qui peuvent affecter les performances d'un algorithme et doivent donc être supprimés. Tous les textes sont convertis en minuscules pour éviter que les algorithmes n'interprètent les mêmes mots avec des cas différents comme différents.

Dans cette partie a chaqye fois q'on va faire une action sur notre data frame on vas ajouter une autre colonne qui contienne le résultat de l'action ajouter

In [8]:
```
string.punctuation
```

Out[8]:
```
'!"#$%&\'()*+,-./:;<=>?@[\\]^_`{|}~'
```

Supprimez les hashtags, les mentions et les caractères indésirables.

1. Le texte généré par l'utilisateur a souvent des bizarreries et des bizarreries. Même au-delà de la conception et des contraintes d'une interface utilisateur particulière, les données textuelles peuvent simplement être difficiles. De plus, chaque fois qu'une plate-forme crée un nouveau

phénomène comme #hashtags, @mentions, $ cashtags ou la possibilité de joindre des médias, elle introduit des modèles uniques de caractères dans les champs de texte associés.

In [9]:
```
def remove_punct(text):
    text  = "".join([char for char in text if char not in string.punctuation])
    text = re.sub('[0-9]+', '', text)
    return text

df['Tweet_punct'] = df['Tweet'].apply(lambda x: remove_punct(x))
df.head(10)
```

Out[9]:

	TweetId	Tweet	Tweet_punct
0	1337494412260069376	RT @milenialparadox: @KataiiKaminaDil @paras_c...	RT milenialparadox KataiiKaminaDil paraschhabr...
1	1337494412256038912	RT @springday29: Summer, 2007 https://t.co/Co9...	RT springday Summer httpstcoCoXXsTtC
2	1337494412243456000	RT @crrdz_: I miss summer ☹ https://t.co/NeDA...	RT crrdz I miss summer ☹ httpstcoNeDArUF
3	1337494412243382279	RT @GamalMohsain: @nytimes Stop ethnic cleansi...	RT GamalMohsain nytimes Stop ethnic cleansing ...
4	1337494412239253506	@Postsubman The first mistake you made is not ...	Postsubman The first mistake you made is not k...
5	1337494412214079498	@AC1DTAB Jae how dare u bring her children in ...	ACDTAB Jae how dare u bring her children in th...
6	1337494412192956416	ma john cena come ha preso la choreo di dynami...	ma john cena come ha preso la choreo di dynami...
7	1337494412184707076	RT @EwdatsGROSS: Good morning https://t.co/kZk...	RT EwdatsGROSS Good morning httpstcokZkpBnARYc
8	1337494412172152838	RT @bigauideaigue: Why mecha and robots have a...	RT bigauideaigue Why mecha and robots have a p...
9	1337494412172124165	@LaurenJauregui Idk what time is for me but I'...	LaurenJauregui Idk what time is for me but I'm...

Supprimez les emojies

In [10]:
```
import re

def remove_emoji(text):
    emoji_pattern = re.compile("["
                           u"\U0001F600-\U0001F64F"  # emoticons
                           u"\U0001F300-\U0001F5FF"  # symbols & pictographs
                           u"\U0001F680-\U0001F6FF"  # transport & map symbols
                           u"\U0001F1E0-\U0001F1FF"  # flags (iOS)
                           u"\U00002702-\U000027B0"
                           u"\U000024C2-\U0001F251"
                           "]+", flags=re.UNICODE)
    text= emoji_pattern.sub(r'', text)
    return text
df['Tweet_emoji']= df['Tweet_punct'].apply(lambda x: remove_emoji(x))
df.head(10)
```

Out[10]:

	TweetId	Tweet	Tweet_punct	Tweet_emoji
0	1337494412260069376	RT @milenialparadox: @KataiiKaminaDil @paras_c...	RT milenialparadox KataiiKaminaDil paraschhabr...	RT milenialparadox KataiiKaminaDil paraschhabr...
1	1337494412256038912	RT @springday29: Summer, 2007 https://t.co/Co9...	RT springday Summer httpstcoCoXXsTtC	RT springday Summer httpstcoCoXXsTtC
2	1337494412243456000	RT @crrdz_: I miss summer ☹ https://t.co/NeDA...	RT crrdz I miss summer ☹ httpstcoNeDArUF	RT crrdz I miss summer httpstcoNeDArUF
3	1337494412243382279	RT @GamalMohsain: @nytimes Stop ethnic cleansi...	RT GamalMohsain nytimes Stop ethnic cleansing ...	RT GamalMohsain nytimes Stop ethnic cleansing ...
4	1337494412239253506	@Postsubman The first mistake you made is not ...	Postsubman The first mistake you made is not k...	Postsubman The first mistake you made is not k...
5	1337494412214079498	@AC1DTAB Jae how dare u bring her children in ...	ACDTAB Jae how dare u bring her children in th...	ACDTAB Jae how dare u bring her children in th...
6	1337494412192956416	ma john cena come ha preso la choreo di dynami...	ma john cena come ha preso la choreo di dynami...	ma john cena come ha preso la choreo di dynami...
7	1337494412184707076	RT @EwdatsGROSS: Good morning https://t.co/kZk...	RT EwdatsGROSS Good morning httpstcokZkpBnARYc	RT EwdatsGROSS Good morning httpstcokZkpBnARYc
8	1337494412172152838	RT @bigauideaigue: Why mecha and robots have a...	RT bigauideaigue Why mecha and robots have a p...	RT bigauideaigue Why mecha and robots have a p...
9	1337494412172124165	@LaurenJauregui Idk what time is for me but I'...	LaurenJauregui Idk what time is for me but I'm...	LaurenJauregui Idk what time is for me but I'm...

Tokenisation, lemmatisation et suppression des mots vides

- Une étape importante du traitement de texte consiste à diviser la chaîne en jetons (ou mots). Il existe de nombreuses façons de diviser une chaîne de texte en jetons (et de nombreuses bibliothèques de traitement de texte et de PNL pour vous aider à le faire). Pour les besoins de cette discussion, nous allons principalement nous intéresser à l'anglais. Dans ce cas, diviser le texte sur des espaces blancs est le moyen le plus simple de le faire. Les vectoriseurs de texte courants - comme ceux de scikit-learn - ont également des jetons un peu plus sophistiqués déjà intégrés que vous pouvez utiliser.

In [11]:
```
def tokenization(text):
    text = re.split(' ', text)
    return text

df['Tweet_tokenized'] = df['Tweet_emoji'].apply(lambda x: tokenization(x.lower()))
df.head()
```

Out[11]:

	TweetId	Tweet	Tweet_punct	Tweet_emoji	Tweet_tokenized
0	1337494412260069376	RT @milenialparadox: @KataiiKaminaDil @paras_c...	RT milenialparadox KataiiKaminaDil paraschhabr...	RT milenialparadox KataiiKaminaDil paraschhabr...	[rt, milenialparadox, kataiikaminadil, parasch...
1	1337494412256038912	RT @springday29: Summer, 2007 https://t.co/Co9...	RT springday Summer httpstcoCoXXsTtC	RT springday Summer httpstcoCoXXsTtC	[rt, springday, summer, , httpstcocoxxsttc]
2	1337494412243456000	RT @crrdz_: I miss summer ☹ https://t.co/NeDA...	RT crrdz I miss summer ☹ httpstcoNeDArUF	RT crrdz I miss summer httpstcoNeDArUF	[rt, crrdz, i, miss, summer, , httpstconedaruf]
3	1337494412243382279	RT @GamalMohsain: @nytimes Stop ethnic cleansi...	RT GamalMohsain nytimes Stop ethnic cleansing ...	RT GamalMohsain nytimes Stop ethnic cleansing ...	[rt, gamalmohsain, nytimes, stop, ethnic, clea...
4	1337494412239253506	@Postsubman The first mistake you made is not ...	Postsubman The first mistake you made is not k...	Postsubman The first mistake you made is not k...	[postsubman, the, first, mistake, you, made, i...

Supprimer les mots vides

- Une autre étape de traitement courante consiste à filtrer les mots qui sont suffisamment communs dans la langue pour qu'ils fournissent peu de valeur. Par exemple, en anglais, l'utilisation du 1 gramme «the» est peu susceptible de fournir un signal précieux dans une tâche de modélisation. De même, «la» ou «le» en français. Ces mots ou jetons peuvent en fait être un signal utile si vous essayez de créer un classificateur de langage textuel, mais ils peuvent également nous conduire à surajuster un modèle sur des mots à faible signal.
- Le choix d'une liste de mots vides adaptée au domaine et à la tâche est un exercice important et précieux qui n'a pas de réponse claire et «correcte». De nombreuses bibliothèques NLP incluent des listes de mots vides intégrées que vous pouvez utiliser, souvent prêtes à l'emploi, par exemple. NLTK et sklearn. Il vaut la peine d'examiner les choix spécifiques que chaque bibliothèque fait avec sa sélection de mots vides pour s'assurer qu'il correspond à vos objectifs et à vos attentes en matière d'inclusion ou de suppression de contenu.

In [12]:
```
stopword = nltk.corpus.stopwords.words('english')
```

In [13]:
```
stopword.extend(['old', 'new', 'age', 'lot', 'bag', 'top', 'cat','rt','the', 'bat
             'mob', 'map', 'car', 'fat', 'sea', 'saw', 'raw', 'rob', 'win', 'can'
             'use', 'pea', 'pit','pot', 'pat', 'ear', 'eye', 'kit', 'pot', 'pen',
              'lid', 'log', 'pr', 'pd', 'cop', 'nyc', 'ny', 'la', 'toy', 'war',
              'pay', 'pet', 'fan', 'fun', 'usd', 'rio',':)', ';)', '(:', '(;', ']
             'thank', 'https', 'since', 'wanna', 'gonna', 'aint', 'http', 'unto',
             'dont', 'done', 'cant', 'werent', 'https', 'u', 'isnt', 'go', 'theyr
            'weve', 'theyve','googleele' , 'goog', 'lyin', 'lie', 'googles', 'goo
             'msft','microsoft', 'google', 'goog', 'googl','goog','https'])
```

In [14]:
```
def remove_stopwords(text):
    text = [word for word in text if word not in stopword]
    return text

df['Tweet_nonstop'] = df['Tweet_tokenized'].apply(lambda x: remove_stopwords(x))
df.head(10)
```

Out[14]:

	TweetId	Tweet	Tweet_punct	Tweet_emoji	Tweet_tokenized
0	1337494412260069376	RT @milenialparadox: @KataiiKaminaDil @paras_c...	RT milenialparadox KataiiKaminaDil paraschhabr...	RT milenialparadox KataiiKaminaDil paraschhabr...	[rt milenialparadox kataiikaminadi parasch..
1	1337494412256038912	RT @springday29: Summer, 2007 https://t.co/Co9...	RT springday Summer httpstcoCoXXsTtC	RT springday Summer httpstcoCoXXsTtC	[rt, springday summer, httpstcocoxxsttc
2	1337494412243456000	RT @crrdz_: I miss summer ☹ https://t.co/NeDA...	RT crrdz I miss summer ☹ httpstcoNeDArUF	RT crrdz I miss summer httpstcoNeDArUF	[rt, crrdz, i, miss summer, httpstconedarut
3	1337494412243382279	RT @GamalMohsain: @nytimes Stop ethnic cleansi...	RT GamalMohsain nytimes Stop ethnic cleansing ...	RT GamalMohsain nytimes Stop ethnic cleansing ...	[rt gamalmohsain nytimes, stop ethnic, clea..
4	1337494412239253506	@Postsubman The first mistake you made is not ...	Postsubman The first mistake you made is not k...	Postsubman The first mistake you made is not k...	[postsubman, the first, mistake you, made, i..
5	1337494412214079498	@AC1DTAB Jae how dare u bring her children in ...	ACDTAB Jae how dare u bring her children in th...	ACDTAB Jae how dare u bring her children in th...	[acdtab, jae, how dare, u, bring her, childr..
6	1337494412192956416	ma john cena come ha preso la choreo di dynami...	ma john cena come ha preso la choreo di dynami...	ma john cena come ha preso la choreo di dynami...	[ma, john, cena come, ha, presc la, choreo, ..
7	1337494412184707076	RT @EwdatsGROSS: Good morning https://t.co/kZk...	RT EwdatsGROSS Good morning httpstcokZkpBnARYc	RT EwdatsGROSS Good morning httpstcokZkpBnARYc	[rt, ewdatsgross good, morning httpstcokzkpb..
8	1337494412172152838	RT @bigauideaigue: Why mecha and robots have a...	RT bigauideaigue Why mecha and robots have a p...	RT bigauideaigue Why mecha and robots have a p...	[rt, bigauideaigue why, mecha, and robots, h..
9	1337494412172124165	@LaurenJauregui Idk what time is for me but I'...	LaurenJauregui Idk what time is for me but I'm...	LaurenJauregui Idk what time is for me but I'm...	[laurenjauregu idk, what, time, is for, me,..

On vas utiliser la bibliothèque NLTK pour effectuer une analyse de chaque tweet et le transformer en un ensemble de mots en suivant les

différentes étapes de base du processus NLP (Natural Language Processing)

- Stemming et Lammitization

In [15]:
```
ps = nltk.PorterStemmer()
def stemming(text):
    text = [ps.stem(word) for word in text]
    return text

df['Tweet_stemmed'] = df['Tweet_nonstop'].apply(lambda x: stemming(x))
df.head()
```

Out[15]:

	TweetId	Tweet	Tweet_punct	Tweet_emoji	Tweet_tokenized	Tv
0	1337494412260069376	RT @milenialparadox: @KataiiKaminaDil @paras_c...	RT milenialparadox KataiiKaminaDil paraschhabr...	RT milenialparadox KataiiKaminaDil paraschhabr...	[rt, milenialparadox, kataiikaminadil, parasch...	[m k
1	1337494412256038912	RT @springday29: Summer, 2007 https://t.co/Co9...	RT springday Summer httpstcoCoXXsTtC	RT springday Summer httpstcoCoXXsTtC	[rt, springday, summer, , httpstcocoxxsttc]	ht
2	1337494412243456000	RT @crrdz_: I miss summer ☹ https://t.co/NeDA...	RT crrdz I miss summer ☹ httpstcoNeDArUF	RT crrdz I miss summer httpstcoNeDArUF	[rt, crrdz, i, miss, summer, , httpstconedaruf]	ht
3	1337494412243382279	RT @GamalMohsain: @nytimes Stop ethnic cleansi...	RT GamalMohsain nytimes Stop ethnic cleansing ...	RT GamalMohsain nytimes Stop ethnic cleansing ...	[rt, gamalmohsain, nytimes, stop, ethnic, clea...	[g
4	1337494412239253506	@Postsubman The first mistake you made is not ...	Postsubman The first mistake you made is not k...	Postsubman The first mistake you made is not k...	[postsubman, the, first, mistake, you, made, i...	n

In [16]:
```
wn = nltk.WordNetLemmatizer()

def lemmatizer(text):
    text = [wn.lemmatize(word) for word in text]
    return text

df['Tweet_lemmatized'] = df['Tweet_stemmed'].apply(lambda x: lemmatizer(x))
df.head()
```

Out[16]:

	TweetId	Tweet	Tweet_punct	Tweet_emoji	Tweet_tokenized	Tv
0	1337494412260069376	RT @milenialparadox: @KataiiKaminaDil @paras_c...	RT milenialparadox KataiiKaminaDil paraschhabr...	RT milenialparadox KataiiKaminaDil paraschhabr...	[rt, milenialparadox, kataiikaminadil, parasch...	[m k
1	1337494412256038912	RT @springday29: Summer, 2007 https://t.co/Co9...	RT springday Summer httpstcoCoXXsTtC	RT springday Summer httpstcoCoXXsTtC	[rt, springday, summer, , httpstcocoxxsttc]	ht
2	1337494412243456000	RT @crrdz_: I miss summer ☹ https://t.co/NeDA...	RT crrdz I miss summer ☹ httpstcoNeDArUF	RT crrdz I miss summer httpstcoNeDArUF	[rt, crrdz, i, miss, summer, , httpstconedaruf]	ht
3	1337494412243382279	RT @GamalMohsain: @nytimes Stop ethnic cleansi...	RT GamalMohsain nytimes Stop ethnic cleansing ...	RT GamalMohsain nytimes Stop ethnic cleansing ...	[rt, gamalmohsain, nytimes, stop, ethnic, clea...	[g
4	1337494412239253506	@Postsubman The first mistake you made is not ...	Postsubman The first mistake you made is not k...	Postsubman The first mistake you made is not k...	[postsubman, the, first, mistake, you, made, i...	n

In [17]:
```
#!pip install wordcloud
#!pip install stylecloud
```

In [5]:
```
from wordcloud import WordCloud, ImageColorGenerator
import stylecloud
import cv2

# Start with one review:
tweet_All = " ".join(review for review in df['Tweet'].apply(lambda x: ' '.join(x)

stylecloud123 =stylecloud.gen_stylecloud(tweet_All)
```

Les Tweets Original

In [18]:
```
from wordcloud import WordCloud, ImageColorGenerator
import stylecloud
import cv2

# Start with one review:
tweet_All = " ".join(review for review in df['Tweet_lemmatized'].apply(lambda x:

stylecloud =stylecloud.gen_stylecloud(tweet_All, icon_name= "fab fa-twitter")
```

Les tweets aprés le traitement

L'ensemble de données après le prétraitement:

In [19]:
```
df.Tweet_lemmatized
```

Out[19]:
```
0        [milenialparadox, kataiikaminadil, paraschhabr...
1                  [springday, summer, , httpstcocoxxsttc]
2                [crrdz, miss, summer, , httpstconedaruf]
3        [gamalmohsain, nytim, stop, ethnic, clean, gen...
4        [postsubman, first, mistak, made, know, partne...
                               ...
11995         [, im, current, cri, want, jungkook, step, ]
11996    [worthwhilerandc, draw, nice, salari, daytoday...
11997    [itsdoctorjoel, alcohol, good, rx, ei, feel, e...
11998                           [louistomlinson, take, hat]
11999    [im, vote, quaranteammonstax, thelockdownaward...
Name: Tweet_lemmatized, Length: 12000, dtype: object
```

On va mettre les tweets propres dans un nouveau fichier csv

In [20]:
```
df.Tweet_lemmatized.to_csv('Datasets/new_tweets_clean.csv',index = False)
```

In [21]:
```
new_tweet_df= pd.read_csv('Datasets/new_tweets_clean.csv')
print('Dataset size:',new_tweet_df.shape)
print('Columns are:',new_tweet_df.columns)
new_tweet_df.info()
new_tweet_df.head()
```

```
Dataset size: (12000, 1)
Columns are: Index(['Tweet_lemmatized'], dtype='object')
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 12000 entries, 0 to 11999
Data columns (total 1 columns):
 #   Column            Non-Null Count  Dtype 
---  ------            --------------  ----- 
 0   Tweet_lemmatized  12000 non-null  object
dtypes: object(1)
memory usage: 93.9+ KB
```

Out[21]:

	Tweet_lemmatized
0	['milenialparadox', 'kataiikaminadil', 'parasc...
1	['springday', 'summer', '', 'httpstcocoxxsttc']
2	['crrdz', 'miss', 'summer', '', 'httpstconedar...
3	['gamalmohsain', 'nytim', 'stop', 'ethnic', 'c...
4	['postsubman', 'first', 'mistak', 'made', 'kno...

Vectorisation

- Les données nettoyées en une seule ligne en passant new_tweet_df dans le CountVectorizer
- La plupart des algorithmes d'apprentissage automatique prêts à l'emploi, par ex. dans sklearn, attendez l'entrée sous la forme d'une matrice de données bidimensionnelle de valeurs numériques: observations (lignes) x caractéristiques (colonnes). Pour créer une représentation numérique de données textuelles, nous devons vectoriser les fonctionnalités de texte (jetons), et des bibliothèques comme sklearn offrent de nombreuses façons de le faire.
- Pour cet exemple, nous utiliserons un vectoriseur qui normalise le nombre de jetons en fonction de la fraction de documents dans laquelle le jeton apparaît. Autrement dit, cela réduira la pondération des jetons qui apparaissent dans chaque document en supposant qu'ils ne sont pas spéciaux, et vice versa pour les jetons peu fréquents. Ce vectoriseur particulier gère également de manière pratique les étapes de prétraitement précédentes que nous avons décrites. En formatant nos étapes «supprimer les URL» et «tokeniser» en tant que fonctions, nous pouvons simplement les passer dans notre vectoriseur en tant qu'arguments de mots clés. De même, nous pouvons transmettre notre liste de mots vides personnalisée pour le filtrage. Il vaut la peine de considérer l'interaction entre la suppression pure et simple des mots vides (avec nos my_stopwords) et la réduction de pondération explicite que des mots

extrêmement courants (comme «le» et «les») recevraient d'une vectorisation TFIDF. Ceci est une autre entrée dans «évaluer l'effet du choix pour votre cas d'utilisation» - ici, nous utilisons les deux pour l'augmentation de l'efficacité de calcul (moins de fonctionnalités).

In [22]:
```
from sklearn.feature_extraction.text import CountVectorizer
cv = CountVectorizer()
X=cv.fit_transform(new_tweet_df.Tweet_lemmatized)
print(X)
```

```
  (0, 17226)    1
  (0, 14815)    1
  (0, 20407)    1
  (0, 23626)    1
  (0, 14482)    1
  (0, 23257)    1
  (0, 14782)    1
  (0, 15695)    1
  (0, 3396)     1
  (0, 3418)     1
  (0, 20765)    1
  (0, 13824)    1
  (1, 24341)    1
  (1, 24794)    1
  (1, 9493)     1
  (2, 24794)    1
  (2, 4488)     1
  (2, 17338)    1
  (2, 11172)    1
  (3, 7588)     1
  (3, 19799)    1
  (3, 24609)    1
  (3, 6434)     1
  (3, 3812)     1
  (3, 7736)     1
  :     :
  (11996, 5720) 1
  (11996, 22744)        1
  (11996, 14411)        1
  (11996, 4431) 1
  (11996, 4389) 1
  (11996, 27732)        1
  (11996, 4900) 1
  (11996, 12402)        1
  (11997, 8019) 1
  (11997, 6850) 1
  (11997, 6045) 1
  (11997, 6157) 1
  (11997, 499)  1
  (11997, 22633)        1
  (11997, 13896)        1
  (11997, 24028)        1
  (11998, 25087)        1
  (11998, 16177)        1
  (11998, 8553) 1
  (11999, 13447)        1
  (11999, 27121)        1
  (11999, 25555)        1
  (11999, 21569)        1
  (11999, 15968)        1
  (11999, 19171)        1
```

Classification des tweets

- Cette approche utilise la technique de création d'un ensemble de mots qui peuvent être classés en toute confiance comme appartenant à une catégorie particulière .

Sélection et réglage d'un modèle

- Il existe de nombreux types d'algorithmes de clustering disponibles dans le commerce via des bibliothèques comme sklearn. Bien que nous n'allions pas les traiter tous dans cette démo, nous comparerons quelques algorithmes différents.

KMeans

- KMeans est un choix courant car il est très rapide pour des quantités modérées de données. Comme la plupart des algorithmes, KMeans a des paramètres qui doivent être choisis de manière appropriée.
- On va Utiliser l'algorithme K-Means pour classer les Tweets en 30 classes.

In [23]:
```
from sklearn.cluster import KMeans
wcss=[]
for i in range(3,30):
    Kmeans=KMeans(n_clusters=i,init='k-means++',max_iter=300,n_init=10,random_sta
    Kmeans.fit(X)
    wcss.append(Kmeans.inertia_)
```

```
Initialization complete
Iteration  0, inertia 160672.000
Iteration  1, inertia 100605.809
Converged at iteration 1: center shift 0.000000e+00 within tolerance 2.967708
e-08
Initialization complete
Iteration  0, inertia 170041.000
Iteration  1, inertia 100210.620
Iteration  2, inertia 100083.864
Iteration  3, inertia 99989.625
Iteration  4, inertia 99976.645
Iteration  5, inertia 99927.014
Iteration  6, inertia 99659.859
Iteration  7, inertia 99391.035
Iteration  8, inertia 99389.667
Converged at iteration 8: center shift 0.000000e+00 within tolerance 2.967708
e-08
Initialization complete
Iteration  0, inertia 136583.000
```

Recherche de clusters optimaux

- Le clustering est une opération non supervisée et KMeans nécessite que nous spécifions le nombre de clusters. Une approche simple consiste à tracer le SSE pour une plage de tailles de cluster. Nous recherchons le «elbow» où l'ESS commence à se stabiliser. MiniBatchKMeans introduit du bruit, j'ai donc augmenté la taille des lots et des init.

Malheureusement, la mise en œuvre régulière de Kmeans est trop lente. Vous remarquerez que différents états aléatoires généreront différents graphiques. Ici, j'ai choisi 30 clusters.

In [24]:
```
import matplotlib.pyplot as plt
plt.plot(range(3,30),wcss)
plt.xlabel('number of clusters')
plt.ylabel('word per cluster')
plt.show()
```

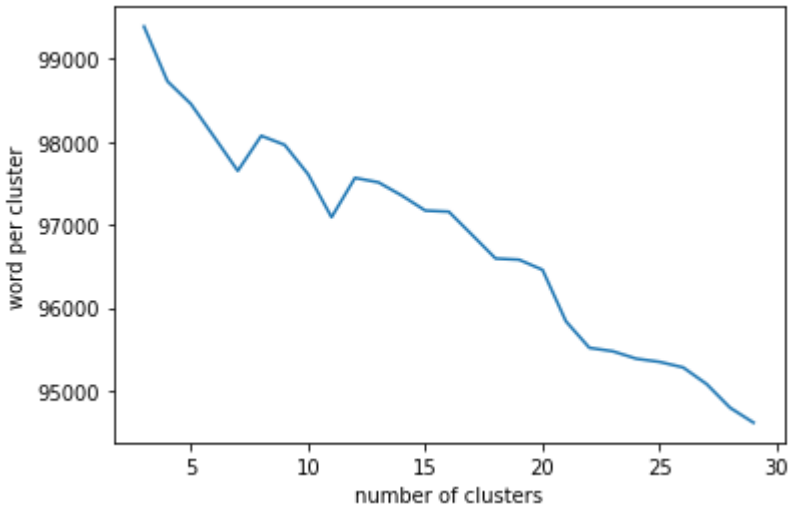

Tracer des clusters

- Ici, nous traçons les clusters générés par notre opération KMeans. Un graphique utilise PCA qui est meilleur pour capturer la structure globale des données. L'autre utilise TSNE qui est meilleur pour capturer les relations entre voisins. Afin d'accélérer le processus avec TSNE, j'échantillonne sur 8000 documents et j'effectue d'abord une réduction de dimension PCA 50 sur les données. Ensuite, je montre un nuage de points échantillonnant davantage l'échantillon jusqu'à 300 points.

In [25]:
```
clusters = KMeans(n_clusters=20,init='k-means++',max_iter=300,n_init=10,random_st
from sklearn.decomposition import PCA
from sklearn.manifold import TSNE
import matplotlib.cm as cm
def plot_tsne_pca(data, labels):
    max_label = max(labels)
    max_items = np.random.choice(range(data.shape[0]), size=8000, replace=False)
    pca = PCA(n_components=2).fit_transform(data[max_items,:].todense())
    tsne = TSNE().fit_transform(PCA(n_components=50).fit_transform(data[max_items
    idx = np.random.choice(range(pca.shape[0]), size=300, replace=False)
    label_subset = labels[max_items]
    label_subset = [cm.hsv(i/max_label) for i in label_subset[idx]]
    f, ax = plt.subplots(1, 2, figsize=(14, 6))
    ax[0].scatter(pca[idx, 0], pca[idx, 1], c=label_subset)
    ax[0].set_title('PCA Cluster Plot')

    ax[1].scatter(tsne[idx, 0], tsne[idx, 1], c=label_subset)
    ax[1].set_title('TSNE Cluster Plot')

plot_tsne_pca(X, clusters)
```

```
Iteration  1, inertia 98706.341
Iteration  2, inertia 97897.377
Iteration  3, inertia 97769.358
Iteration  4, inertia 97652.104
Iteration  5, inertia 97586.054
Iteration  6, inertia 97446.326
Iteration  7, inertia 97162.257
Iteration  8, inertia 97067.226
Iteration  9, inertia 97066.951
Converged at iteration 9: center shift 0.000000e+00 within tolerance 2.967708
e-08
```

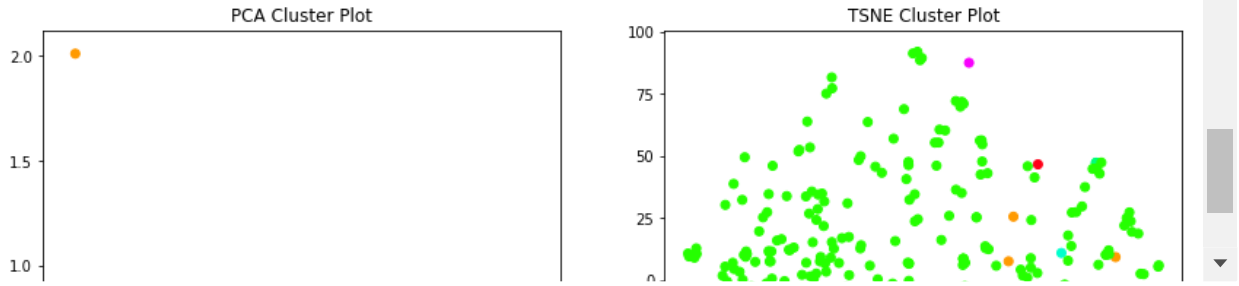

In [26]:
```
true_k=30
Kmeans=KMeans(n_clusters=true_k,init='k-means++',n_init=1)
Kmeans.fit(X)
```

Out[26]:
```
KMeans(algorithm='auto', copy_x=True, init='k-means++', max_iter=300,
       n_clusters=30, n_init=1, n_jobs=None, precompute_distances='auto',
       random_state=None, tol=0.0001, verbose=0)
```

Mots clés principaux

- Enfin, nous allons parcourir les clusters et imprimer les meilleurs mots-clés en fonction de leur score TFIDF pour voir si nous pouvons repérer des tendances. Je vais le faire en calculant une valeur moyenne pour toutes les dimensions dans Pandas, regroupées par l'étiquette de

cluster. En utilisant numpy, trouver les premiers mots consiste simplement à trier les valeurs moyennes de chaque ligne et à prendre le N supérieur.

- Vous pouvez voir que nous avons un très bon résultat. Des sujets tels que l'exploitation des enfants, la fraude fiscale, les droits civils et les problèmes environnementaux peuvent être déduits des principaux mots clés. D'autres approches intéressantes à ce sujet pourraient inclure la modélisation de sujets LDA ou éventuellement le travail avec des incorporations de mots pré-entraînées.

In [27]:
```
print("Top terms per cluster:")
order_centroids = Kmeans.cluster_centers_.argsort()[:, ::-1]
terms = cv.get_feature_names()
for i in range(true_k):
    print("Cluster %d:" % i)
    print("-----------------------")
    for ind in order_centroids[i, :10]:
        print(' %s' % terms[ind])
    print()
print("\n")
```

```
Top terms per cluster:
Cluster 0:
-----------------------
 one
 thing
 day
 time
 know
 ever
 good
 life
 amp
 best

Cluster 1:
-----------------------
 like
 look
 feel
```

Dans cette partie on va pour chaque cluster afficher un seul tweet

- on a choisi d'afficher la tweet original sans aucune modification

In [28]:
```
i=0
j=0
while i<28:
    while True:
        Y=cv.transform([new_tweet_df.Tweet_lemmatized[j]])
        prediction=Kmeans.predict(Y)
        if i == prediction:
            print("Tweet of cluster "+str(prediction)+" : "+df.Tweet[j])
            print ("----------------------------------------------")
            print("\n")
            j=0
            break
        j+=1
    i+=1
```

```
Tweet of cluster [0] : RT @TakeAShilllPill: I hope we all agree on this one f
rfr. https://t.co/wNFxO9WPgx (https://t.co/wNFxO9WPgx)
----------------------------------------------


Tweet of cluster [1] : RT @GOPChairwoman: “But you know what real collusion l
ooks like? It’s when left-leaning media, that is the media in general, decide
en mass…
----------------------------------------------


Tweet of cluster [2] : @Capitalntel At least 🤡 guess we’ll just keep buyin
g..
----------------------------------------------


Tweet of cluster [3] : RT @thetojodojo: 🔒YAKUZA REMASTERED COLLECTION GIVEAW
AY 🔒
```

Tweets par catégorie

Nous souhaitons créer une dataframe contenant le nombre total de tweets par catégorie. Une base de données 4D avec la colonne d'index remplie d'utilisateurs et 3 autres colonnes contenant le nombre total de tweets de l'utilisateur dans les classes sociales, culturelles, sanitaires et économiques. Cela peut être réalisé d'abord en créant un bloc de données contenant les scores Jaccard pour chaque tweet pour chaque catégorie, puis en attribuant un tweet à une catégorie en fonction du score le plus élevé et enfin en regroupant les tweets par nom d'utilisateur et somme des tweets.

Ensembles de mots

Le bloc ci-dessous représente des mots liés à l'économie,social,culture et senté.

In [6]:
```
economy_related_words = "agriculture infrastructure capitalism trading service se
social_related_words = " emotion excuse shield creative persistence  enthusiastic
culture_related_words = "arts humanities philosophy literature music painting bel
health_related_words =  "asthma band aid bandage be allergic to be constipated be
```

In [7]:
```
nlp = en_core_web_sm.load()
tokenizer = RegexpTokenizer(r'\w+')
lemmatizer = WordNetLemmatizer()
stop = set(nltk.corpus.stopwords.words('english'))
punctuation = list(string.punctuation)
stop.update(punctuation)
w_tokenizer = WhitespaceTokenizer()
def furnished(text):
    final_text = []
    for i in w_tokenizer.tokenize(text):
        if i.lower() not in stop:
            word1 = lemmatizer.lemmatize(i)
            final_text.append(word1.lower())
    return " ".join(final_text)
df.Tweet = df.Tweet.apply(furnished)
```

Tout comme les tweets, ils doivent subir un pré-traitement. La fonction fournie utilisée sur les tweets est appliquée sur les sets.

In [8]:
```
economy = furnished(economy_related_words)
social = furnished(social_related_words)
culture = furnished(culture_related_words)
health = furnished(health_related_words)
```

Les doublons sont également supprimés:

In [9]:
```
string1 = economy
words = string1.split()
economy = " ".join(sorted(set(words), key=words.index))
economy
string1 = social
words = string1.split()
social = " ".join(sorted(set(words), key=words.index))
social
string1 = health
words = string1.split()
health = " ".join(sorted(set(words), key=words.index))
health
string1 = culture
words = string1.split()
culture = " ".join(sorted(set(words), key=words.index))
culture
```

Out[9]:
```
'art humanity philosophy literature music painting belief ethos intellectual ac
hievement principle activity visual fine art, music, lifestyle custom tradition
habit background civilisationuk civilizationus heritage more society value way
life convention development ethnicity ethnology folklore folkways grounding hum
anism idea knowledge science community nation race people origin ancestry ethni
c group lineage state population extraction pedigree clan tribe living national
ity identity descent style parentage colorus cultural colouruk attainment polit
y social order world heredity root racial type strain human mankind humankind r
ubric prescription rule past history ethnos situation condition naturalisationu
k allegiance political home confederation body politic country affiliation resi
dence native land enfranchisement minority naturalizationus national status beh
aviouruk position regime conduct routine behaviorus populace fate lot existence
station citizenry doctrine essence circumstance manner personage business kind
kin progeny environment play daily acting mode everyday region realm standard s
et empire commonwealth republic federation sovereignty organizationus instituti
on citizen entity public union kingdom organisationuk fatherland motherland sov
ranty homeland resident inhabitant democracy territory power superpower domain
micronation sovereign dominion principality monarchy nation-state re publica co
mmonality general collective klatch fold klatsch denizen burgher'
```

In [10]:
```
def jaccard_similarity(query, document):
    intersection = set(query).intersection(set(document))
    union = set(query).union(set(document))
    return len(intersection)/len(union)
def get_scores(group,tweets):
    scores = []
    for tweet in tweets:
        s = jaccard_similarity(group, tweet)
        scores.append(s)
    return scores
e_scores = get_scores(economy, df.Tweet.to_list())
s_scores = get_scores(social, df.Tweet.to_list())
c_scores = get_scores(culture, df.Tweet.to_list())
h_scores = get_scores(health, df.Tweet.to_list())
```

In [11]:
```
# create a jaccard scored df.
data  = {'names':df.TweetId.to_list(),       'economic_score':e_scores,
         'social_score': s_scores, 'culture_score':c_scores, 'health_scores':h_sc
scores_df = pd.DataFrame(data)
#assign classes based on highest score
def get_classes(l1, l2, l3, l4):
    econ = []
    socio = []
    cul = []
    heal = []
    for i, j, k, l in zip(l1, l2, l3, l4):
        m = max(i, j, k, l)
        if m == i:
            econ.append(1)
        else:
            econ.append(0)
        if m == j:
            socio.append(1)
        else:
            socio.append(0)
        if m == k:
            cul.append(1)
        else:
            cul.append(0)
        if m == l:
            heal.append(1)
        else:
            heal.append(0)

    return econ, socio, cul, heal
l1 = scores_df.economic_score.to_list()
l2 = scores_df.social_score.to_list()
l3 = scores_df.culture_score.to_list()
l4 = scores_df.health_scores.to_list()
econ, socio, cul, heal = get_classes(l1, l2, l3, l4)
data = {'name': scores_df.names.to_list(), 'economic':econ, 'social':socio, 'cult
class_df = pd.DataFrame(data)
#grouping the tweets by username
new_groups_df = class_df.groupby(['name']).sum()
#add a new totals column
new_groups_df['total'] = new_groups_df['health'] + new_groups_df['culture'] + new
#add a new totals row
new_groups_df.loc["Total"] = new_groups_df.sum()
```

In [12]:
```
scores_df
```

Out[12]:

	names	economic_score	social_score	culture_score	health_scores
0	1337494412260069376	0.636364	0.633333	0.656250	0.656250
1	1337494412256038912	0.486486	0.562500	0.542857	0.500000
2	1337494412243456000	0.447368	0.470588	0.459459	0.459459
3	1337494412243382279	0.555556	0.645161	0.571429	0.571429
4	1337494412239253506	0.638889	0.542857	0.567568	0.611111
...	...	...	...	...	...
11995	1337494373936877569	0.542857	0.484848	0.558824	0.558824
11996	1337494373936721921	0.657143	0.656250	0.676471	0.676471
11997	1337494373936689152	0.645161	0.703704	0.612903	0.666667
11998	1337494373928407041	0.433333	0.461538	0.448276	0.448276
11999	1337494373920071681	0.647059	0.593750	0.617647	0.617647

12000 rows × 5 columns

In [13]:
```
new_groups_df
```

Out[13]:

name	economic	social	culture	health	total
1337494373920071681	1	0	0	0	1
1337494373928407041	0	1	0	0	1
1337494373936689152	0	1	0	0	1
1337494373936721921	0	0	1	1	2
1337494373936877569	0	0	1	1	2
...	...	...	...	...	...
1337494412243382279	0	1	0	0	1
1337494412243456000	0	1	0	0	1
1337494412256038912	0	1	0	0	1
1337494412260069376	0	0	1	1	2
Total	1258	3958	4039	5488	14743

12001 rows × 5 columns

Vous trouverez ci-dessous un graphique à secteurs pour montrer les volumes de tweets dans les différentes catégories:

In [22]:
```
fig = plt.figure(figsize =(10, 7))
a = new_groups_df.drop(['total'], axis = 1)
plt.pie(a.loc['Total'], labels = a.columns)
plt.title('A pie chart showing the volumes of tweets under different categories.'
plt.show()
```

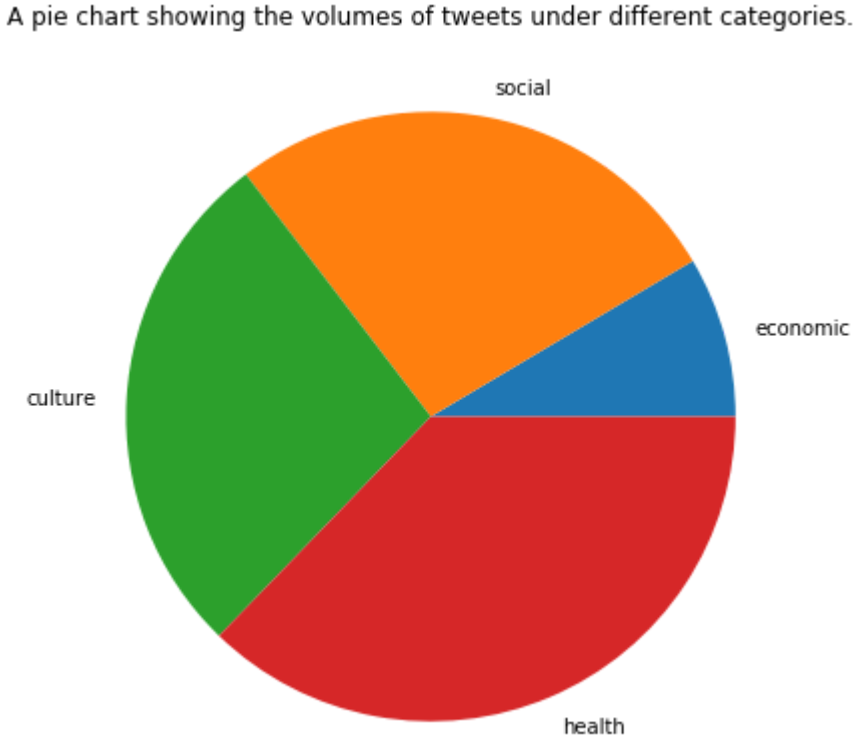

Conclusion

le plus grand pourcentage pour le secteur de santé cela pourrait être le résultat de la pandémie actuelle dont tout le monde parle ,ainsi que le secteur social puisque j'ai mis des suivres pour plusieur page de cinema et music et de football . Les données peuvent être utilisées pour de nombreuses analyses et de belles visualisations, mais notre objectif de est clustering des tweets.